ИИ-ассистент технической поддержки

RAG

поиск +
ответ +
источник

RAG-поиск по базе знаний, Telegram-интерфейс
и безопасный агентный workflow

Дипломный проект курса

Коптелов Кирилл Викторович

2026

Задача и пользователь

Сотрудник технической поддержки работает с повторяющимися обращениями

Проблема

- Инструкции распределены по файлам и их трудно быстро сопоставить с формулировкой обращения.
- Ответ нужно проверить: неверная инструкция увеличивает время решения и риск ошибки.

Что получает сотрудник

Вопрос на естественном языке

Решение по найденному контексту

Ссылка на исходный документ

Эскалация, если ответа в базе нет

Почему нужен RAG

Семантический поиск связывает вопрос с фрагментом базы знаний

Обычный поиск

Ищет совпадения слов

Не формирует объяснение

Источник нужно искать вручную

RAG

Находит близкие фрагменты

Собирает ответ по контексту

Передаёт источники в Telegram

Граница знаний

Score guard

Fallback вместо выдуманного ответа

Эскалация к специалисту

База знаний и границы корпуса

В демонстрации используется фактически индексируемый набор технических инструкций

Темы базы

Учётные записи и MFA
VPN, Wi-Fi и DNS
Почта и браузер
Рабочее место и принтеры
Инциденты и доступы

Принцип использования

- Индексируются документы из заданного RAG-каталога.
- Ответ ссылается на найденный контекст, а не на общие знания модели.
- Вопрос вне корпуса получает fallback и не показывает источники.

Архитектура и путь запроса

Разделение пользовательского интерфейса, API, RAG и инфраструктуры



PostgreSQL хранит историю и feedback. Redis используется для cache и rate limit. Qdrant хранит векторы. Phoenix сохраняет trace.

Выбор модели и retrieval

Финальная конфигурация зафиксирована после изолированного сравнения

Embedding

BAAI/bge-m3

Семантическое представление вопросов и документов

Vector store

Qdrant

Поиск близких фрагментов и metadata источников

Chunking

512 / 64

Recursive chunks и overlap 64 токена

Top-K

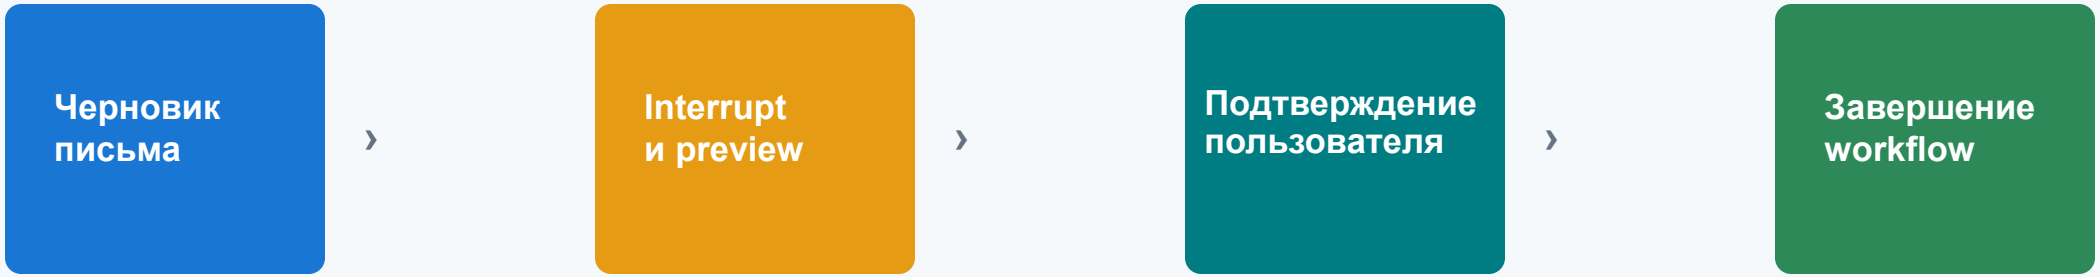
5

Компромисс качества и задержки

Альтернатива: меньший top-K быстрее, но в сравнении дал меньшую долю ответов с опорой на источник. Поэтому выбран top-K 5.

Агентный workflow с подтверждением

Нешаблонное действие отделено от подготовки черновика



До interrupt внешнего действия нет. После resume=true workflow фиксирует выполнение. SMTP в учебном контуре намеренно не подключён.

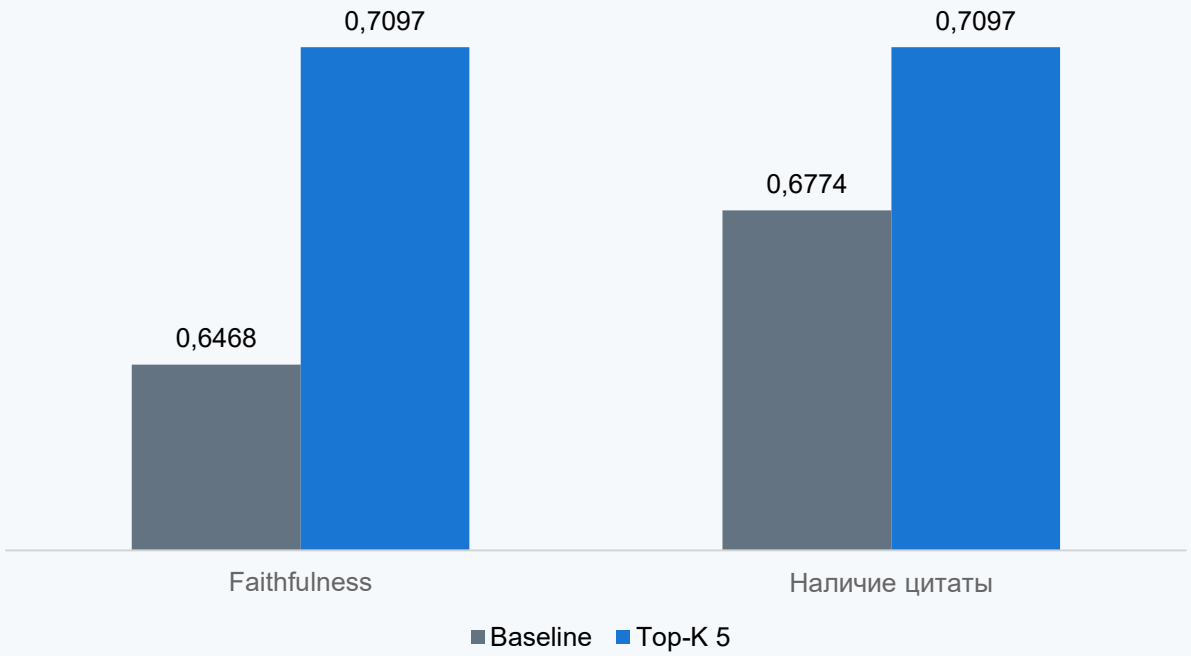
Надёжность, безопасность и наблюдаемость

Система обрабатывает ошибки и оставляет технический след запроса

Недостаточный контекст	Fallback и эскалация
Опасное действие	Interrupt до подтверждения
Персональные данные	PII-redaction и moderation
Проблема в запросе	X-Request-ID и Phoenix trace

Проверка качества RAG

31 вручную подготовленный вопрос и сравнение конфигураций



Цена выбора

Baseline
5.59 с

Top-K 5
7.57 с

+1.98 с за более высокую опору на источники

Подтверждённые сценарии демонстрации

Все примеры вручную проверены в Telegram после технической репетиции

Принтер	Пустые страницы	04-printer.txt
VPN	Authentication failed	02-vpn.txt
MFA	Смена телефона	06-mfa.txt
Граница	Командировка за границу	Fallback без источников

Telegram показывает ответ и компактные источники только для содержательного RAG-ответа.

Ограничения и дальнейшее развитие

- Качество ответа ограничено составом и актуальностью базы знаний.
- Fallback защищает от выдуманного ответа, но не заменяет работу специалиста.
- Для production нужны управление доступом к документам, политика обновления корпуса и реальная интеграция почтового провайдера.

Итог: ассистент сокращает поиск решения, сохраняет проверяемость ответа и передаёт сложные случаи человеку.

Спасибо за внимание